


```
marp: true
theme: uncover
paginate: true
backgroundColor: #0d0d0d
color: #f0f0f0
style: |
section {
font-family: 'Inter', 'Helvetica Neue', sans-serif;
font-size: 1.8rem;
padding: 60px;
}
h1 {
color: #ffffff;
font-size: 2.6rem;
```

Und ChatGPT?

Das Modell liest **jeden Token gleichzeitig** — und vergleicht ihn mit jedem anderen.

Beide nennen das *Aufmerksamkeit*.

■ Aber es sind völlig verschiedene Dinge.

Das Problem: zu viel Input

Jede Sekunde erreichen dein Gehirn **Millionen von Reizen**.

Es kann nur einen Bruchteil verarbeiten.

Lösung: Aufmerksamkeit als Filter.

3 Aufmerksamkeitssysteme

Alerting — *Wann* soll ich aufpassen?

Orienting — *Was* soll ich anschauen?

Executive — *Wie* verarbeite ich es?

Bottom-up vs. Top-down

Bottom-up: Ein lauter Knall zieht dich automatisch ab.

Keine Entscheidung — einfach passiert.

Top-down: Du suchst gezielt deine Freundin.

Du steuerst, was du siehst.

Der Cocktail-Party-Effekt

Dutzende Gespräche gleichzeitig. Lärm überall.

Und dann: jemand sagt **deinen Namen**.

Dein Gehirn hat den ganzen Raum abgehört —
ohne dass du es wusstest.

Bedeutung steuert Fokus

Dein Gehirn ignoriert Gleichgültiges.

Emotion, Relevanz, Überraschung —
das sind die echten Aufmerksamkeits-Trigger.

Bedeutung ist der Schlüssel.

Schritt 1: Wörter werden zu Zahlen

Jedes Wort → **Embedding** (Zahlenvektor im Bedeutungsraum)

- **Positional Encoding** (wo steht das Wort?)

Erst dann kann gerechnet werden.

Query · Key · Value

Jedes Wort stellt eine **Frage** (Query).

Jedes andere Wort gibt eine **Antwort** (Key).

Je besser die Antwort passt → desto mehr **Inhalt** (Value) fließt ein.

Attention Score

Wie stark beeinflusst Wort A das Verständnis von Wort B?

Das wird **für jedes Wortpaar berechnet**.

Ergebnis: eine Gewichtungsmatrix für den ganzen Satz.

Multi-Head Attention

Nicht einer, sondern **viele Köpfe** rechnen gleichzeitig.

Jeder Head sieht den Satz anders:

Grammatik · Bedeutung · Position · Kontext

Am Ende werden alle Perspektiven zusammengeführt.

Präzision ohne Verständnis

Der Transformer weiß nicht, was *Apfel* ist.

Er weiß: nach *roter* kommt **statistisch** oft *Apfel*.

Kein Körper. Keine Erinnerung. Keine Bedeutung.

Nur Muster in Trainingsdaten.

Gehirn vs. Transformer

	Gehirn	Transformer
Steuerung	flexibel, zielgerichtet	datengetrieben, fix
Basis	Bedeutung & Emotion	Statistik & Muster
Kapazität	begrenzt, sparsam	parallelisiert, rechenintensiv
Lernen	sofort, aus Erfahrung	iterativ, aus Texten

Was Transformer besser können

- ✓ **Millionen Tokens gleichzeitig** verarbeiten
- ✓ Kein Vergessen, keine Erschöpfung
- ✓ Immer gleich — keine Tagesverfassung

Was dein Gehirn besser kann

- ✓ **Einen neuen Buchstaben einmal sehen** — und nie vergessen
- ✓ Ironie, Tonfall, Sarkasmus verstehen
- ✓ Bedeutung aus minimalem Input ableiten
- ✓ **20 Watt** statt 500 Watt

Ist das überhaupt Aufmerksamkeit?

Wenn ein Transformer entscheidet, Wort A höher zu gewichten —
ist das **Aufmerksamkeit**?

Oder nur sehr schnelle Statistik?

Schreib es mir in die Kommentare.

Zwei Systeme. Ein Ziel.

Dein Gehirn **bedeutet** — der Transformer **berechnet**.

Beide filtern. Beide priorisieren.

Aber auf komplementäre Art.

Die Zukunft liegt vielleicht dazwischen.

Was denkst du?

Wenn dir das Thema gefallen hat:

Like · Kommentar · Abonnieren

Nächstes Video: *Wie lernen Transformer überhaupt?*

→ *maximleopold.com*